

Local AI Agent With RAG · Logical Flow

· Project Overview

A fully local RAG system using Ollama with Llama 3.2 for inference and Chroma vector database for retrieval of pizza restaurant reviews · no cloud APIs required.

· Complete Logical Flow

```
.....
·                               Local AI Agent With RAG                               ·
.....
·
·   .....  SETUP (One-time)  .....
·
·   CSV Reviews File
·   ·
·   ·
·   .....
·   ·   vector.py
·   ·
·   ·   1. Load CSV data
·   ·   ·
·   ·   ·
·   ·   2. Generate Embeddings
·   ·       Model: mxbai-embed-large
·   ·       (Local via Ollama)
·   ·   ·
·   ·   ·
·   ·   3. Store in Chroma DB
·   ·       (Persistent local storage)
·   ·
·   .....
·
·   .....  QUERY FLOW  .....
·
·   User Question (CLI)
·   ·
·   ·
·   .....
·   ·   Step 1: Vector Retrieval
·   ·
·   ·   Embed question
·   ·   ·
·   ·   ·
·   ·   Chroma DB similarity search
·   ·   ·
·   ·   ·
·   ·   Return 5 most relevant reviews
·   ·
·   .....
·
·   ·
·   ·
```

```

. ....
.   Step 2: Prompt Construction   .
.   .                             .
.   ChatPromptTemplate:         .
.   "You are a pizza restaurant expert" .
.   + Retrieved reviews as context .
.   + User question             .
. ....
.   .                             .
.   .                             .
. ....
.   Step 3: Local LLM Inference .
.   .                             .
.   Model: Llama 3.2 (via Ollama) .
.   100% Local · No API calls    .
. ....
.   .                             .
.   .                             .
. Context-Aware Answer          .
. (Based on actual reviews)    .
.   .                             .
.   .                             .
. Display · Loop for next question .
.   .                             .
. ....

```

.. Architecture

```

All Local · No Cloud Dependencies
Ollama (mxbai-embed-large) · Embeddings
Chroma DB                  · Vector Storage
Ollama (Llama 3.2)         · LLM Inference

```