

Production Grade RAG Python App · Logical Flow

· Project Overview

A production-ready RAG application combining Inngest for event-driven workflows, Qdrant for vector storage, and OpenAI for embeddings and LLM generation.

· Complete Logical Flow

```
.....
·           Production Grade RAG Application           ·
.....
·
·   .....  INGESTION PIPELINE  .....
·
·   PDF Document
·   ·
·   ·
·   Inngest Event: "ingest"
·   (Throttled: 2/min, Rate limit: 1/4hr)
·   ·
·   ·
·   .....
·   ·   data_loader.py   ·
·   ·
·   ·   Step 1: Load PDF   ·
·   ·   ·
·   ·   ·
·   ·   Step 2: Chunk into segments   ·
·   ·   ·
·   ·   ·
·   ·   Step 3: OpenAI Embedding   ·
·   ·   (text-embedding model)   ·
·   ·   .....
·   ·   ·
·   ·   ·
·   ·   .....
·   ·   vector_db.py   ·
·   ·
·   ·   Qdrant Upsert
·   ·   ... Vector embeddings
·   ·   ... Payload (chunk text)
·   ·   ... Collection management
·   ·   .....
·
·   .....  QUERY PIPELINE  .....
·
·   User Question
·   ·
·   ·
·   Inngest Event: "query"
·
```

```

.      .
.      .
.      .....
.  .  Step 1: Embed Question      .
.  .  ... OpenAI text-embedding  .
.      .....
.      .
.      .
.      .....
.  .  Step 2: Semantic Search    .
.  .  ... Qdrant vector similarity .
.  .  ... Return top-k chunks    .
.      .....
.      .
.      .
.      .....
.  .  Step 3: Generate Answer    .
.  .  ... Context: retrieved chunks .
.  .  ... Question: user query    .
.  .  ... OpenAI GPT completion   .
.      .....
.      .
.      .
.  Return Context-Aware Answer   .
.
.      .....

```

.. Production Features

```

Inngest Workflow Engine:
... Throttling (2 events/min)
... Rate Limiting (1 per 4 hours)
... Automatic retries
... Event-driven architecture

```